AnalystBot 작업 지시 — 북아일랜드-조지아 재실행 결함 전체 수정(단계별)

Oct 6, 2026 · @jung youngjin

0. 지위·진단·순서

`docs/fable/inbox/2026-10-06_workorder_nir_geo_fixes.md`. 이전 지시서 전부 아래의 실행 지시서이고, 충돌하면 이 문서가 이긴다. **§1은 하위 과제의 실행 방식을 바꾼다 — 서치 재구축 §2의 "하위 = 에이전트 루프"를 이 문서가 대체한다.** 검증층·판정층·DeepSeek 단계·해석 규칙 작업은 그대로다.

진단(카드 원문 기준 — 보고서 요약이 아니라)

#	원문	뜻
1	하위 8개 전부 `후보 0 · 검증 0`, `budget_cut: 하위 출력(추론 포함) 8386/8000 · 밟은 턴 7 → 판정층 변수 0개`	에이전트 루프가 추론 토큰으로 상한을 다 쓰고 done 전에 끊긴다. 상한을 올려도 또 넘는다(4k→8k에서 6.7k→8.4k). **올리는 걸로는 안 끝난다**
2	벽시계 26.8분, 20초+ 공백 26개 = 17.6분, 전부 Solar 턴(40~88초/턴)	시간의 3분의 2가 루프 턴이다. 턴 수를 줄여야 한다
3	`전송 실패 8건 — 응답없음 8건 · Solar 동시 호출 4`	긴 턴이 타임아웃으로 끊긴다(429 아님)
4	`§12-b 위반 'Georgia squad 2 UEFA Nations League B Grp. 2'`, `'... return Oct 5'`	템플릿 질의에 대회 전체명·조·날짜가 섞여 문지기에 걸린다
5	date_missing 20(전 6) — 세 번째 경로(`_remember_body`) 수정됨, 라이브 미검증	날짜 배선은 경로마다 따로 끊겨 있었다
6	근거에서 뺀 R1을 DeepSeek 문장이 그대로 인용	제외 변수가 DeepSeek 입력에 남아 있다
7	보고서는 "전송 실패 1건", 카드는 "8건"	보고가 원문과 다르다
8	오늘 $4.88 / $5.00 — 재실행 한 번 $0.34	수정 확인을 매번 라이브로 해서 돈과 시간이 다 나간다

순서: §5(카세트 재생 — 이후 모든 확인을 공짜로) → §1 → §2 → §3 → §4 → §6 → §7 계약 → §8 검수. §5를 먼저 하는 이유: 이 문서의 나머지 수정은 전부 재생으로 확인할 수 있고, 라이브는 마지막 검수 1~2회만 쓴다.

1. 하위 과제 — 코드가 찾고, LLM은 한 번 읽는다

에이전트 루프(LLM이 검색어를 정하고 → 검색 → 다시 생각 → fetch → 다시 생각 → done)는 턴마다 추론 토큰을 쓰고 40~88초가 걸린다. 하위 8개 × 7턴이 26분과 budget_cut의 원인이다. **찾는 일은 코드가, 읽고 뽑는 일만 LLM이 한 번에** 하게 바꾼다.

하위 과제 하나의 새 흐름 (`app/research/subtasks.py`의 `run_subtask`)

1. **질의 생성(코드)** — §2 규칙으로 씨앗 질의 2개(영어 1 + 팀 현지어 1). KBO·K리그·한국 대표팀은 한국어 2개.
2. **검색(코드)** — 질의마다 SearXNG(time_range=week) 1회. 결과가 5건 미만인 질의만 Bing 뉴스 RSS 1회 추가. GDELT는 경기당 4회 상한 그대로. 하위당 검색 상한 3회 유지.
3. **거르기·재정렬(코드)** — 기존 순서: 도메인 등급 → 신원 선필터 → 날짜 힌트 → 재정렬 1단(현지 매체 가산 포함) → 상위 **3건** fetch(기존 2에서 3. 경기 합계 fetch 상한 24로 조정).
4. **본문 문단(코드)** — 문서마다 BM25 상위 20 → 재정렬 상위 6 → 하위당 최대 18문단. 문단마다 `[D1-P3] (도메인, 발행일)` 머리표를 붙인다.
5. **추출(LLM 1회)** — Solar에 "아래 문단에서 담당 유형({유형 목록})의 변수만 JSON으로 뽑아라. quote는 문단의 글자 그대로, source는 머리표로" 를 보낸다. 출력은 done 스키마의 variables 배열과 같은 꼴(M47). 도구 없음. `max_tokens` 4,000, `reasoning_effort=low`(요청 본문에 실리는지 원장으로 확인). 타임아웃 120초, 재시도 1회.
6. **좁히기 2차(조건부, 최대 1회)** — 추출 결과가 0개이고 하위 검색 예산이 남았으면, 1차 결과 제목·스니펫에서 코드가 고유명사(선수·감독명) 상위 2개를 뽑아 `{팀} {고유명사}` 질의로 3~5단계를 한 번 더. LLM이 질의를 만들지 않는다.

결과: 하위당 LLM 호출 1~2회(전: 7턴). 하위 8개 병렬, Solar 동시 4 → 이론상 추출 단계 2라운드 × 30~60초. 목표 경기당 6분 이하.

그대로 두는 것: 하위 분할 표(유형군 4 × 팀), 장부(searched/found/empty), 리드 병합·2차 보충 1회, 검증층, 출처 표기. 에이전트 루프 코드는 **삭제하지 않고** 오픈월드 ⑥단(경기 찾기)에서만 쓴다 — 하위 과제 경로에서는 호출하지 않는다(계약 M128).

예산 재조정 — 하위 출력 상한 8,000 → 4,000(추출 한 번이면 충분), 경기 출력 64,000 → 40,000(원래 값으로 복귀). fetch 경기 상한 16 → 24.

2. 질의 생성 규칙

원문: `'Georgia squad 2 UEFA Nations League B Grp. 2'`, `'Northern Ireland national team return Oct 5'` — 템플릿 변수에 대회 전체명(조 포함)과 날짜가 그대로 들어가 §12-b 문지기에 걸렸다.

대회 짧은 이름 — `competition_short(full)` 한 함수(정본 하나, 사본 금지):

- 조·라운드·리그 등급 꼬리 제거: `Grp. 2`, `Group A`, `Round of 16`, `Matchday 5`, `B` / `C` 리그 표시, `2026-27` 같은 시즌 표기.

- 결과 예: `UEFA Nations League B Grp. 2` → `Nations League`, `FIFA ASEAN Cup Final` → `ASEAN Cup`, `KBO 리그` → `KBO`.
- 매핑 표가 필요하면 `config/competition_short.yaml`(데이터). 표에 없으면 꼬리 제거 규칙만 적용.

템플릿 변수 제한 — 질의 템플릿에 쓸 수 있는 변수는 `{team}`(영어 짧은 표기 또는 현지어 표기), `{opp}`, `{comp}`(= competition_short), `{coach}`, `{player}`, `{word}`(유형 핵심어, search_words.yaml)뿐. 날짜·숫자·조 번호·라운드 변수는 템플릿에서 금지 — `time_range=week`가 날짜를 대신한다.

사전 검사(템플릿 로드 시) — 봇 시작 시 모든 템플릿을 고정물 경기 셋(인도네시아-태국, 북아일랜드-조지아, KIA-LG)으로 렌더링해 §12-b 문지기와 길이 규칙(3~10단어)을 통과하는지 확인한다. 하나라도 걸리면 **시작 실패**(조용히 건너뛰지 않는다). 같은 검사를 계약으로도 둔다(M129).

§12-b 문지기 자체는 바꾸지 않는다 — 문지기가 맞게 막았다. 고칠 곳은 질의를 만드는 쪽이다.

3. 날짜 배선 전수 확인·전송 실패 처리

날짜 — 경로를 하나로 만든다. 이번 주에 날짜가 끊긴 경로가 셋이었다(fetch 신규·본문 재사용·세포 `_remember_body`). 경로마다 고치는 방식은 네 번째를 또 만든다.

- 본문을 저장하는 함수를 **하나**로 만든다: `store_doc(url, body, published_at, date_source)`. 본문을 쓰는 모든 경로(§1 하위 fetch·오픈월드·세포·재사용)가 이 함수만 부른다. 본문과 날짜를 따로 쓰는 경로가 남으면 계약 M130이 빨개진다(AST로 `bodies[...] =` 직접 대입·`_` 로 날짜 버리기를 app/ 전체에서 탐지 — M124 확장).
- 검증층의 날짜 조회도 한 함수: `doc_date(url)`. 재사용이든 신규든 같은 저장소에서 읽는다.
- 측정: 고정물 재생(§5)으로 북아일랜드-조지아를 돌려 `date_missing`이 0~2인지 확인. 남은 건 페이지에 날짜가 정말 없는 경우만이어야 하고, 건마다 "htmldate 호출됨·None"이 로그에 있어야 한다.

전송 실패(응답없음 8건)

- §1로 턴이 줄면 긴 응답이 줄어 대부분 사라질 것이다. 그래도 남는 것에 대비:
- 타임아웃 120초, 재시도 1회(지수 대기 2초). 재시도 후에도 실패하면 그 하위는 `llm_timeout` 사유로 장부에 남기고 2차 보충 대상.
- 사유 분리 유지: `llm_timeout` · `llm_http_5xx` · `llm_429` · `budget_cut`은 서로 다른 사유다(④에서 한 분리 유지). 429가 한 번이라도 나면 동시 호출 4 → 2.
- 카드 블록 1의 전송 실패 집계를 **보고서도 그대로** 쓴다(§6).

4. 가설 근거 구멍 막기

원문: 북아일랜드 근거에서 R1(h2h 표본 1)은 뺐는데, DeepSeek 문장 "h2h 패턴이 count=1로 단일 근거지만 … 전방 압박이 살아난다(R1)"이 통과했다. 원인: 제외 표시는 판정층에만 있고, **DeepSeek 입력에는 R1이 그대로 들어갔다.**

두 겹으로 막는다

1. **입력에서 뺀다(원인 제거)** — `HypoInput.variables`에는 가설 근거로 쓸 수 있는 변수만 넣는다. 표본 부족·검증 탈락·충돌 버림 변수는 `context_only` 목록으로 따로 보내고, 프롬프트에 "context_only의 변수는 번호로 인용하지 마라. 근거로 쓰지 마라"를 적는다. 반증 단계(단계 4)도 같은 분리.
2. **출력에서 거른다(안전망)** — DeepSeek가 돌려준 가설 문장·시나리오 driver_vars에 근거 불가 변수 번호가 있으면: 가설 문장은 **그 문장을 버리고** 사유 `cited_excluded:R1`을 블록 5에 적는다(문장을 고쳐 쓰지 않는다). 시나리오는 그 번호만 driver_vars에서 빼고, 남은 driver가 0개면 시나리오를 버린다(`unknown_var`와 같은 처리).

문장이 다 버려진 팀 — 그 팀 가설이 0문장이 되면 조지아와 같은 "근거 변수 없음" 경로로 간다.

5. 개발 재실행은 카세트 재생 — 돈·시간 0

오늘 하루 예산 $5 중 $4.88을 수정 확인용 재실행에 썼다. 한 번에 $0.34·26분. 이 문서의 수정 대부분(질의 규칙·날짜 배선·가설 거르기·판정 표기)은 **같은 검색 결과와 같은 LLM 응답**으로 확인할 수 있다.

녹화 — 라이브 실행 때 외부 호출을 전부 기록한다: SearXNG·Bing·GDELT 응답, fetch 본문(원문 HTML), Solar·DeepSeek 요청·응답. 저장 위치 `cassettes/{경기 id}/{실행 id}/`, 요청 해시 → 응답. 원장의 "카세트 재생" 기능이 이미 있으면 그것을 확장한다(사본 금지).

재생 — `--replay {실행 id}` 플래그. 요청 해시가 카세트에 있으면 응답을 그대로 돌려주고, **없으면 기본은 실패**(`replay_miss` 사유와 요청 내용을 출력). `--replay-fallthrough`를 줄 때만 없는 요청을 라이브로 보내고 카세트에 추가한다.

무엇을 재생으로 확인하나

바뀐 곳	재생으로 확인 가능?
날짜 배선(§3), 가설 거르기(§4), 판정·표기	✓ 같은 입력, 공짜
질의 규칙(§2)	질의가 바뀌면 검색 요청이 달라져 replay_miss — fallthrough로 검색만 라이브(무료 통로), LLM은 재생
하위 실행 방식(§1)	LLM 요청이 바뀌므로 LLM만 라이브 — 검색·fetch는 재생

라이브는 검수에만 — §8의 최종 검수 1회(+ 재분석 1회)만 라이브로 돈다. 그 전 확인은 전부 재생·fallthrough로. 하루 상한 값은 사용자 결정 사항이라 이 작업에서 올리지 않는다.

6. 보고 정확성 규칙

원문은 "전송 실패 8건", 보고는 "1건"이었다. 사용자는 보고를 보고 판단한다 — 보고가 원문과 다르면 판단이 틀린다.

- **수치는 카드·원장·깔때기 원문에서 복사한다.** 로그를 따로 grep해서 센 수를 보고에 쓰지 않는다. 둘이 다르면 둘 다 적고 "불일치"로 표시한 뒤 원인을 찾는다.
- 보고의 7단계 표 각 칸에는 근거 원문 한 줄(카드의 해당 줄을 그대로)을 붙인다.
- 하위별 표는 `tools/research_report.py` 출력을 그대로 붙인다(손으로 다시 만들지 않는다). 칸이 0이면 "0"과 "측정 안 됨"을 구분해 적는다(출력 토큰 0 사건).
- "고쳤다"는 보고에는 그 수정을 **재생 또는 라이브로 확인한 실행 id**를 붙인다. 확인 실행이 없으면 "고쳤으나 미확인"으로 적는다.

7. 계약 M128~M136과 돌연변이

전부 행동 검사(실제로 돌려서 본다). 글자 검사 금지 — 이번 세션에 글자 검사 계약이 돌연변이를 다섯 번 통과시켰다. 고정물은 북아일랜드-조지아 카세트(§5 첫 녹화분)를 쓴다.

번호	계약	돌연변이(빨개져야 함)
M128	하위 과제 경로에서 에이전트 루프가 호출되지 않는다 — 하위당 LLM 호출 ⩽ 2	하위 경로에서 agentloop.run 호출
M129	모든 질의 템플릿이 고정물 3경기로 렌더링 시 §12-b·길이 규칙 통과, 걸리면 봇 시작 실패	사전 검사 끄기 / competition_short 대신 전체명
M130	본문 저장은 store_doc 하나뿐 — app/ 어디서든 bodies 직접 대입·날짜 버리기가 있으면 실패(AST)	한 경로에서 bodies[url]= 직접 대입
M131	재사용 본문을 인용한 변수도 날짜를 가진다(고정물: 두 하위가 같은 URL)	재사용 경로가 store_doc 우회
M132	context_only 변수는 HypoInput.variables에 없다	제외 변수를 variables에 다시 넣기
M133	DeepSeek 문장이 근거 불가 번호를 인용하면 그 문장은 버려지고 cited_excluded 사유가 남는다	출력 거르기 끄기
M134	재생 모드에서 카세트에 없는 요청은 replay_miss로 실패(fallthrough 없이)	없는 요청을 라이브로 보내기
M135	추출 호출 요청 본문에 reasoning_effort=low와 max_tokens=4000이 실린다(실제 요청 객체 검사)	칸 빼기

번호	계약	돌연변이(빨개져야 함)
M136	llm_timeout·llm_429·llm_http_5xx·budget_cut 사유가 서로 섞이지 않는다	타임아웃을 budget_cut으로

8. 검수 순서·합격표·금지·보고

단계별 실행 순서 (각 단계: 계약 빨강 → 구현 → 초록 → 돌연변이 빨강 → WIP 커밋 → 한 줄 보고)

1. §5 카세트 — 녹화·재생·replay_miss(M134). 확인: 지난 실행 로그에서 녹화본을 만들 수 없으면, 다음 라이브 1회를 녹화본으로 쓴다(그 전까지 2~5는 고정물 단위 계약으로만 확인).
2. §2 질의 규칙(M129) — 확인: 재생+fallthrough(검색만 라이브).
3. §3 날짜 단일 경로(M130·M131)·전송 사유(M136) — 확인: 재생, date_missing 0~2.
4. §4 가설 구멍(M132·M133) — 확인: 재생, R1 인용 문장 사라짐.
5. §1 하위 실행 방식(M128·M135) — 확인: 검색·fetch 재생 + LLM 라이브, 하위당 LLM ≤2, 하위 출력 ≤4,000, budget_cut 0.
6. 전체 스위트(30초 안팎)·돌연변이 M128~M136 전부 빨강.
7. **라이브 검수 1회** — 지금부터 36시간 안 실제 경기 1개(축구 또는 KBO, 사용자가 지정하면 그것). 녹화 켜고.
8. **재분석 1회** — 같은 경기에 "재분석" 명령. 확정 XI가 나왔으면 반영되는지, 안 나왔으면 상한이 그대로인지.

라이브 검수 합격표

항목	기준
벽시계	6분 이하
하위	8/8 장부 기록, budget_cut 0, LLM 호출 하위당 ≤2
변수	에이전트 출처 검증 변수 8개+, 4유형군 중 3군+ found, 양 팀 각각 2개+
날짜	date_missing 0~2(남은 건 페이지에 날짜 없음 로그)
질의	§12-b 위반 0
가설	근거 불가 번호 인용 0
시나리오·대입	DeepSeek 4+, 블록 7~8 대입 출력, 블록 9 방향 문장(거짓 사유 없음)
비용	$0.5 이하
재분석	같은 경기 카드 갱신 확인

금지: 상한을 올려서 budget_cut 해결 / 하루 비용 상한 변경 / 수정 확인을 라이브로(검수 2회 외) / 글자 검사 계약 / 검증층·필수형·거짓 1.0 계약 약화 / 문지기(§12-b) 완화 / git stash·치환 후 diff 생략·테스트 중 실 API.

보고: 단계마다 `§n 완료 — 계약 x/x · 돌연변이 y/y · 확인 실행 id · 커밋` . 라이브 검수는 카드 전문 + 합격표(칸마다 카드 원문 한 줄) + research_report 출력 원문. 시간 상한 단계당 2시간. 넘거나 갈림길이면 멈추고 보고.